

도심지 교통흐름 및 미세먼지 예측을 위한 딥러닝 LSTM 프레임워크

A Deep Learning LSTM Framework for Urban Traffic Flow and Fine Dust Prediction

저자 (Authors)	이홍석, 부이 각 남, 선충녕 Hongsuk Yi, Khac-Hoai Nam Bui, Choong-Nyoung Seon
출처 (Source)	정보과학회논문지 47(3) , 2020.3, 292-297(6 pages) Journal of KIIE 47(3) , 2020.3, 292-297(6 pages)
발행처 (Publisher)	한국정보과학회 The Korean Institute of Information Scientists and Engineers
URL	http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE09313086
APA Style	이홍석, 부이 각 남, 선충녕 (2020). 도심지 교통흐름 및 미세먼지 예측을 위한 딥러닝 LSTM 프레임워크. 정보과학회논문지, 47(3), 292-297
이용정보 (Accessed)	부산도서관 210.103.83.*** 2021/09/24 13:52 (KST)

저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

도심지 교통흐름 및 미세먼지 예측을 위한 딥러닝 LSTM 프레임워크 (A Deep Learning LSTM Framework for Urban Traffic Flow and Fine Dust Prediction)

이 홍 석 [†] 부이 각 남 ^{††} 선 충 념 ^{††}
(Hongsuk Yi) (Khac-Hoai Nam Bui) (Choong-Nyoung Seon)

요 약 정확하고 시기 적절한 예측은 스마트시티의 성공적인 추진을 위한 중요한 단계이다. 매일 수집되는 교통 데이터의 급격한 성장으로, 도심지에서 단기 교통 예측을 위한 최근 연구는 장단기메모리 LSTM(Long-Short Term Memory) 기반의 딥러닝으로 집중되고 있다. 하지만 단기 (5분) LSTM 모델은 실시간 비선형 교통흐름 예측에는 한계가 있다. 더욱이, 교통 데이터에 기반한 미세먼지 예측은 또한 매우 시급한 연구 분야이다. 따라서 본 논문에서는, 중기/장기 예측을 지원하기 위한 멀티 층 LSTM 프레임워크를 설계하였다. 또한 교통데이터 기반 미세먼지 흐름을 예측하기 위한 컨볼루션 ConvLSTM (Convolutional LSTM) 모델을 개발하였다. 교통흐름 예측을 위하여 대전시 중심도로의 차량검지기 VDS (Vehicle Detection System) 데이터를 활용하였다. 실험 결과 본 논문에서 제안한 모델은 우수한 예측 성능을 보여주었다.

키워드: 딥러닝, 장단기 메모리, 교통흐름 예측, 도심지 미세먼지 예측

Abstract Accurate and timely forecasting is an essential step for the successful deployment of smart cities. With the rapid growth of traffic data collected daily, recent studies have focused on deep learning based on long-term short term memory (LSTM) for short-term traffic prediction, especially in urban areas. However, the short-term (five minutes) LSTM model is limited in the real-time nonlinear traffic flow prediction. Moreover, the fine dust prediction based on traffic data is also an emerging issue in this research area. Thus, this paper designs the multiple traffic data-based multi-input/output LSTM framework for supporting medium and long-term prediction. Additionally, a convolutional LSTM (ConvLSTM) model is developed for predicting fine dust flow based on traffic data. Regarding the experiment, we analyzed data from the Vehicle Detection System (VDS) located on major roads in Daejeon City for the evaluation. The experiment indicates promising results for the proposed approach.

Keywords: deep learning, long short term memory, traffic flow prediction, fine dust prediction

· 이 논문은 2018년도 정부(과학기술정보통신부)의 재원으로 정보통신기술진흥센터의 지원을 받아 수행된 연구임(No. 2018-0-00494, 딥러닝 기반 도심지 교통혼잡 예측 및 신호제어 솔루션 시스템)

· 이 논문은 2019 한국컴퓨터종합학술대회에서 '장단기 교통흐름 예측을 위한 딥러닝 LSTM 신경망'의 제목으로 발표된 논문을 확장한 것임

[†] 정 회 원 : 한국과학기술정보연구원 슈퍼컴퓨팅응용센터 책임(KISTI)
hsyi@kisti.re.kr

(Corresponding author)

^{††} 비 회 원 : 한국과학기술정보연구원 슈퍼컴퓨팅응용센터 선임
hoainam.bk2012@gmail.com
silowisp@kisti.re.kr

논문접수 : 2019년 9월 3일

(Received 3 September 2019)

논문수정 : 2020년 1월 3일

(Revised 3 January 2020)

심사완료 : 2020년 1월 17일

(Accepted 17 January 2020)

Copyright©2020 한국정보과학회 : 개인 목적이나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.
정보과학회논문지 제47권 제3호(2020. 3)

1. 서론

최근 딥러닝은 합성곱 신경망(Convolutional Neural Network, CNN) 기술의 향상으로 급격한 발전을 이루었다[1]. 특히, CNN 분야에서는, 기존 전문가들이 해왔던 100개가 넘는 깊은(Deep) 신경망 구조를 자동으로 탐색(Search)하는 자동화기계학습(AutoML) 분야로 발전하고 있다. 딥러닝을 활용한 기술 중에서도 시계열 데이터 기반 순환신경망(Recurrent Neural Network, RNN) 분야도 큰 성공을 거두었다. RNN의 한 알고리즘인 장단기메모리(Long-Short Term Memory, LSTM)의 성공은 날씨, 주식, 그리고 교통 흐름 예측 등 수 많은 사회현안을 해결하는데 핵심적인 역할을 하고 있다[2]. 딥러닝을 이용하면 기존기술로는 파악하기 어려운 데이터 패턴을 추출할 수 있는 가능성이 있어서, 딥러닝 기술 적용이 시급히 요구되고 있다.

한편, 도심지에서 교통흐름은 시간별, 요일별 등에 따른 비선형적인 특성이 있어서[3] 기존의 방법으로는 설명하기가 어려웠다[4]. 지금까지 LSTM을 이용하여 도심지에서 교통흐름 예측은 주로 단위 단기예측이고[5-7], 지능형교통체계(Intelligent Transport System, ITS)에서 교통흐름을 선제적으로 대응하기 위해서는 중장기에 예측하는 기술도 필요하다.

본 연구에서는 대도시 주요 혼잡도로를 대상으로 교통혼잡을 예측하기 위해, 대전시 차량검지기 VDS(Vehicle Detection System) 데이터를 분석하였다. 도로의 여건을 고려한 혼잡도로에서 VDS의 데이터(교통량, 평균속도, 점유율)을 중기예측 및 장기예측이 가능하도록 멀티-클래스 입출력 구조를 만들어 지도학습 기반의 LSTM 모형을 설계하였다. 또한 요일별 및 통행 차량의 크기에 따른 1시간 중기예측과 24시간 장기예측의 정확도를 비교하여, 혼잡도로의 장단기 기억에 내포되어 있었던, 교

통흐름의 비선형적인 패턴을 매우 정확하게 예측할 수 있다. 또한 날씨와 같은 환경 요소는 교통 흐름에 영향을 줄 것으로 예상된다. 이러한 특징을 활용하여 본 연구에서 제안한 모델을 개선하기 위해 미세먼지를 대상으로 한 위치기반 시계열 처리의 선행연구 결과를 소개한다. 실제 도심지 미세먼지 데이터에 대해 ConvLSTM을 활용한 모델을 개발하고, 이 모델이 효과적으로 학습됨을 보인다.

2. 연구내용 및 방법

지금까지 교통혼잡비용 해마다 약 30조원을 줄이기 위하여 수 많은 연구들이 있었지만, 기존의 연구방법으로는 교통혼잡비용이 줄어들지 않고 있다. 최근 딥러닝을 이용한 교통흐름을 예측하고, 데이터 패턴을 활용하여 교차로 신호들의 현시를 제어하는 프로젝트가 진행되고 있다. 실제로 교통 속도, 교통량, 점유율 데이터를 이용하여 교통흐름을 예측한다. 또한 교차로의 차량을 영상 기반으로 교통량을 분석하여 강화학습 기반으로 교통량을 조정하는 연구들이 시도되고 있다. 그림 1은 딥트랙(Deep-TraC) 프레임워크로 도심지 주요 혼잡도로의 교통데이터를 딥러닝 LSTM으로 예측하여, 패턴 기반으로 신호를 제어한다. 더불어 미세먼지, 날씨 등 이미지 기반의 시계열 데이터를 딥러닝을 예측하여 미세먼지와 교통흐름과의 관계를 파악할 수 있는 CNN과 LSTM의 혼합 신경망 프레임워크이다.

2.1 대전시 주요도로의 차량검지기 데이터

우선 ITS 분야에서 교통흐름을 측정하기 위해서, 도심지 주요도로에서 차량검지기 VDS를 설치하며, 특히 교통공학 측면에서 관심이 많은 장소에서 주로 설치하여 데이터 실시간으로 수집한다. 대전시 주요도로 21군데 설치된 1달 동안의 데이터, 즉, 2017년 4월 1일에서




그림 1 딥러닝 기반 교통흐름 예측 및 통한 교통신호 제어 시스템

Fig. 1 Structure of deep learning based traffic congestion prediction and signal control system




그림 2 대전시 주요 관심도로의 VDS 교통량
Fig. 2 VDS traffic volume data for DaeJeon City




그림 3 VDS35 도로의 교통량, 속도 사이의 상관관계분포
Fig. 3 Density distribution of traffic volume and speed for VDS35

4월 30일 사이, 데이터를 분석하였다. VDS는 차량별 교통량, 속도, 점유율 등 특성을 가지고 있으며, 매 5분마다 평균 값들이 기록된 데이터이다.

그림 2에서는 21곳 중에서 교통량을 기준으로 관심이 있는 4군데를 분석한 그림이다. 교통량이 매우 큰 지역(VDS22)은 대전시 유성구 홈플러스 인근 편도 6차선 도로이고, 교통량이 가장 적은 지역(VDS18)은 서구로 터널과 강으로 막혀 있는 도로이며, 가장 혼잡한 도로는 중구 백화점이 있는 도로로 VDS34, VDS35이다. 본 연구에서는 VDS35를 중심으로 딥러닝 LSTM 중기, 장기 예측 코드를 개발하고자 한다.

그림 3은 백화점 등 주요 상권이 발달되어 있는 도로가 포함된 곳으로 VDS35에서 교통량과 평균속도 사이의 관계를 확률밀도로 나타낸 것이다. 교통량이 크면 평균속도는 줄어들고, 평균 속도가 높다는 것은 교통량이 적은 것으로 해석이 된다.

2.2 멀티 입출력이 가능하도록 LSTM 구조 설계

VDS 데이터를 이용한 딥러닝 LSTM의 핵심은 지도




그림 4 LSTM 입출력 기억을 위한 룩백과 룩포워드 구조
Fig. 4 LSTM architecture of look-back and look-forward

학습 기반 입력 및 출력 레이블(Label)의 설계이다. 멀티-클래스 기반 지도학습을 위해, 출력층의 레이블을 룩포워드(LF) 변수로 설정하여, 단기예측은 LF를 1로(5분) 설정하며, 장기예측은 LF를 288(24시간)로 설정할 수 있도록 구조를 설계하였다. 또한 LSTM의 장단기 기억을 변수로 조정할 수 있도록 룩백(LB)을 추가하였다. 또한, VDS의 멀티-출력을 주는 차량별 교통량(4개), 속도, 점유율 등 총 6개의 특성을 가지고 멀티-특성 구조로 설계하였다.

그림 4는 VDS 데이터의 특성을 고려한 LSTM 지도 학습 기반의 입출력을 나타낸 것으로, 멀티-특성, 멀티-레이블링, 장단기기억을 고려하면, 3차원 구조로 설계할 수 있다. LSTM 뉴럴 네트워크 구조를 구현한 코드는 구글 텐서플로우 본백을 사용하는 케라스 프레임워크를 사용하였다. LSTM 구조는 계산시간을 고려하여 신경망 2개를 사용하였다. 또한 각각의 32개, 128개의 뉴런을 사용했다. 입력데이터 학습 과정에서 뉴런의 개수와 룩포워드, 룩백의 변수에 따라서 오버피팅이 발생하는 데, 이때는 드롭아웃 0.5로 조정하였다. 또한 배치 사이즈는 128개이고, 다른 하이퍼파라미터는 디폴트값을 사용하였다.

3. 연구 결과

3.1 교통 흐름 예측 결과

VDS 데이터는 구간별 도로에 통과한 차량별 교통량을 분석할 수 있다. 차량의 크기에 따라서 소형차량(SM), 중형차량(MD), 대형차량(LG), 그리고 이들의 합인 총차량(TR)의 교통량을 추출할 수 있다.

그림 5는 VDS35 대상도로에서 2017년 4월 26일(수요일)에 측정된 차량의 교통량, 속도, 점유율을 중기예측을 한 것이다. 여기서, 룩백은 3시간(LB=36), 룩포워드는 1시간(LF=12)로 설정하였다. 실제 데이터와 중기예측된 데이터는 큰 차이가 있음을 알 수 있다. LSTM 입장에서 보면, 주어진 시공간에서 룩백(LB) 기억만큼 학습하고, 바로 룩포워드(LF)를 예측하는 것이다. 향후

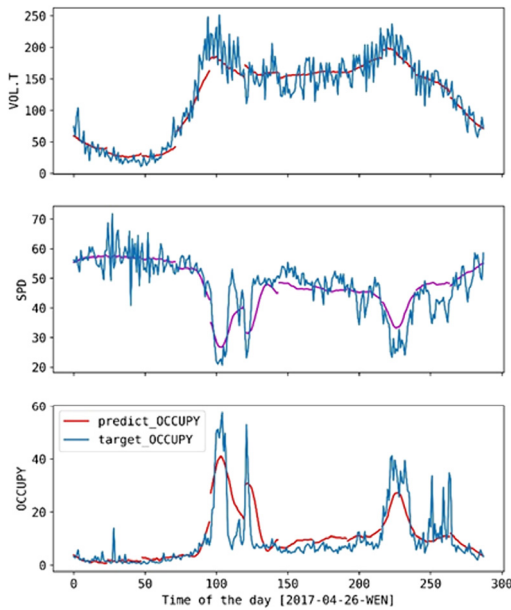


그림 5 VDS35 중기예측(LB=36, LF=12)
Fig. 5 Mid-term prediction for VDS35

학습데이터를 충분히 확보하면 성능은 개선될 수는 있을 것이다.

가운데 그림은 평균속도이고, 세로축의 값(SPD)은 구간 평균속도로 km/h 단위이고, 가로축은 시간(Hour) 단위이다. 혼잡도로의 평균속도 패턴은 교통에서 잘 알려진 오전시간(8시~9시)과 오후시간(6시~8시)에 정체가 주로 발생하며, 속도는 20~30km/h로 주중에 주기적인 혼잡이 발생한 것을 알 수 있다. 중기 예측을 통해서 혼잡시간에도 급격한 속도가 떨어지는 경향을 잘 따라감을 알 수 있다. 마지막 판넬은 실제측정한 점유율과 중기예측한 점유율을 나타낸 것으로, 평균속도 결과와 비슷하게 혼잡시간에 비선형적인 패턴을 매우 잘 설명하고 있음을 알 수 있다.

이제 본 연구에서 개발한 중기예측 결과를 기존 단기 예측(5분단위)와 비교해보자. 실제 단기예측은 룩포워드를 1(LF=1)을 사용하므로, 실제 데이터를 따르는 패턴을 보인다. 하지만 실제 사회현안 문제에서 실시간을 대처하기에는 5분 단위 예측은 너무 짧아서 교통혼잡을 선제적으로 대응하기에는 어려움이 있다. 하지만 중기예측을 통해서 급격하게 변화하는 오전/오후 침투구간에 중기예측은 커브를 잘 설명하고 있음을 알 수 있다. 또한 중기예측은 교통사고 등 돌발사고가 발생했을 경우도 1시간 정도 예측을 할 수 있음을 알 수 있다.

3.2 미세먼지 예측 결과

이제 교통흐름에 영향을 미치는 환경요인 중에서 미

세먼지에 대해 살펴보자. 2019년에는 미세먼지 경보 발령이 여러 차례 있었으며 이 경보의 영향으로 교통혼잡의 경향이 변화할 수 있을 것으로 예상된다. 미세먼지가 교통 흐름 미치는 영향에 파악하는 것은 매우 어렵고, 대부분 연구 초기 단계이다. 본 연구에서는 대전시 VDS 데이터와 미세먼지 데이터를 융합하기 위한 초기 연구 단계이다. 미세먼지는 풍향이나 풍속, 그리고 계절 등 다양한 요소에 영향을 받고 관측소별 위치에 따라서도 영향을 줄 수 있기 때문에 미세먼지 예측 문제는 이미지 시계열 문제로 간주할 수 있다. 즉, 미세먼지 데이터는 도심 전체에서 측정하는 시공간 이미지 데이터로 볼 수 있다. 다양한 정보를 사용하기 전에, 이전 시간대에 관측된 미세먼지와 다양한 대기 정보를 활용하여 시계열 예측을 적용한다.

표 1은 사용된 대전시 미세먼지 데이터의 일부를 보여주고 있다. 전체 딥러닝을 위해 확보한 데이터는 2018년 1월 1일에서 2018년 12월 31일까지 1년간 관측한 총 89,600개 항목으로 구성되어 있다. 데이터에는 1시간대별로 관측소 위치, NO₂, O₃, CO, SO₂, PM₁₀, PM_{2.5} 등의 실제로 관측한 값을 포함한다.

그림 6은 대전시에서 측정하고 있는 미세먼지 관측 위치를 중심으로 이미지화를 한 것이다. 미세먼지 관측소 중 교통관측 위치와 연계가 쉬운 대상을 선별하여 3×3 격자로 시계열 미세먼지 이미지를 만들었다. 대상이 되는 대전시 미세먼지 관측소의 위치는 교통 관측과 연계될 수 있는 8곳을 선정하였다. 관측소 인근에 교통 측정소가 있는 경우로 제한하였으며, 노은동, 구성동, 읍내동, 월평동, 둔산동, 성남동, 상대동, 대흥동을 포함하였으며, 상대동의 경우 2018년 하반기부터 관측정보가 있기 때문에 제외하였다. 미세먼지 이미지는 전체 격자를 3×3으로 하고, 관측소가 배치되는 7셀은 관측값을 할당하고 상대동 및 관측소가 없는 셀은 0으로 설정하여 이미지로 구성하였다.

미세먼지 예측은 한 장소에서도 적용할 수도 있지만 주변 관측결과에 영향을 받고, 시간에 따라 전파될 수 있기 때문에 단순한 시계열을 사용하는 LSTM보다는

표 1 대전시 미세먼지 데이터
Table 1 Daejeon City fine dust data

date	location	NO ₂	O ₃	CO	SO ₂	PM ₁₀	PM ₂₅
2018123124	읍내동	0.045	0.001	1.5	0.006	53	35
2018123124	문평동	0.036	0.005	0.9	0.004	58	38
2018123124	문창동	0.041	0.001	1.1	0.005	53	44
2018123124	구성동	0.029	0.005	0.8	0.004	56	38
2018123124	노은동	0.052	0.001	0.7	0.005	88	45
2018123124	상대동	0.043	0.002	1	0.004	72	65
2018123124	대흥동 1	0.032	0.002	1.1	0.01	74	42

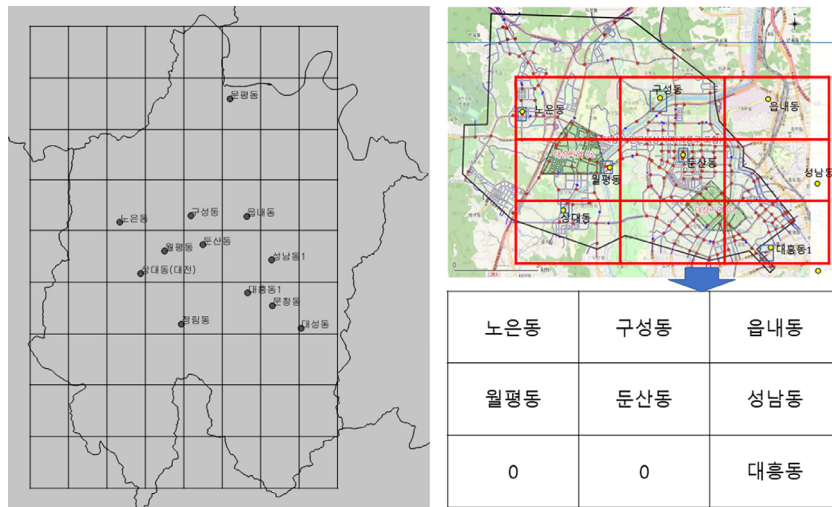


그림 6 미세먼지 예측을 위한 ConvLSTM 그리드

Fig. 6 The grid of ConvLSTM for fine dust prediction

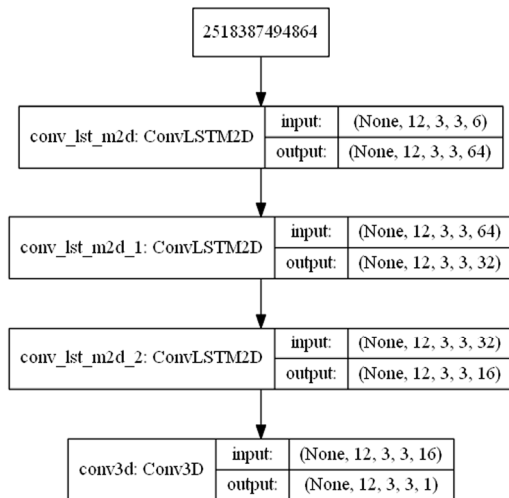


그림 7 3×3 격자 기반 ConvLSTM 모델

Fig. 7 3×3 grid based ConvLSTM model

이미지를 시계열로 분석할 수 있는 방법이 적절하다. 위치 정보를 컨볼루션 신경망으로 추출하고 다시 LSTM으로 시계열을 적용하는 LRCN방법보다 입력과 은닉(hidden), 게이트(gate) 등을 직접 컨볼루션으로 구성하는 ConvLSTM이 이런 문제에 더 적합하다. 따라서, 공간에 대한 시계열 예측에서 많이 활용된 ConvLSTM을 이용해 미세먼지를 예측하는 모델을 설계하였다[9]. 딥러닝 Keras 프레임워크에는 ConvLSTM 함수가 있어서, 미세먼지처럼 시계열 이미지 데이터를 예측할 수 있다. 그림 7은 ConvLSTM을 3계층으로 쌓아서 모델을

구성한 것이다. 여기서는 딥러닝 신경망 아키텍처 구성을 3개의 2차원 ConvLSTM2D 루틴을 사용하였고, 필터 크기는 3×3이다. 실제로 입력은 3×3로 구성되며, 채널을 통해 6가지 종류의 입력을 배치하였다. 컨볼루션을 위한 필터의 크기는 3×3을 사용하였다. 미세먼지 이미지 입력 크기가 작기 때문에 줄어들지 않도록 패딩(padding)을 통해 크기가 유지되도록 설정하였다. 3계층마다 필터의 개수를 64,32,16개를 배치하여 상위의 ConvLSTM으로 올라갈수록 추상화될 수 있도록 설계하였다. 계산량을 고려하여 최종적인 모델을 출력하기 위해 완전연결된(full-connected) 신경망을 사용하지 않고 컨볼루션 층으로 처리하였다.

본 연구에서는 PM10 미세먼지를 우선 고려하여 학습을 하였고, 사용된 데이터의 70%는 훈련(training)에 사용하였으며, 이중에 10%는 검증(validation) 데이터로




그림 8 ConvLSTM 신경망을 대전시 미세먼지 예측

Fig. 8 The convergence of loss for fine-dust prediction

모델을 평가하였다. 훈련에 사용하지 않은 나머지 30%는 테스트(test) 데이터 셋을 구성하였다. 그림 8은 200번 반복된 미세먼지 PM10의 실제 관측치와 예측치 사이의 차이를 MSE(Mean Squared Error)로 계산하여 오차(Loss)를 표시한 것이다. 학습 결과는 매우 잘 수렴하고 있음을 알 수 있다.

4. 결론

본 논문에서는 대전시 교통혼잡 주요도로의 교통흐름 예측을 위하여 딥러닝 LSTM의 입출력 구조를 3차원으로 설계하였다. 3차원 LSTM 지도학습 설계는, VDS 특성에 맞추어 6개의 특성 차원과, 도로의 장단기 기억을 처리하는 룩백, 출력층에 해당하는 장단기 예측을 처리하는 룩포워드를 레이블링으로 처리하였다. 또한 교통데이터의 특성을 동시에 처리하여 소형, 중형, 대형, 그리고 총합 교통량을 멀티-특성로 출력이 가능하였다. 멀티-레이블링 방법으로 LB를 이용한 1시간 중기예측이 속도 및 점유율에서 매우 우수함을 알 수 있었다.

이상의 결과로부터, 도심지 혼잡지역에서 발생하는 교통흐름 예측은 1시간 정도 중기예측을 통해서 예측정확도를 높이고, 또한 단기예측보다 충분히 교통신호 제어 등 선제적 대응을 할 수 있는 플랫폼 개발이 추가로 필요함을 알 수 있다. 마지막으로, 특정구간에 갑자기 발생하는 점유율은 돌발 상황으로, LSTM으로 학습한 데이터만 충분하다면 중기예측으로 돌발상황도 예측이 가능할 것이다. 또한 도심지에서 미세먼지 예측을 3x3 격자 크기의 이미지를 시계열로 만들어서, 장단기메모리로 예측하는 방법을 고안하였다. 실제로 미세먼지와 교통흐름 사이의 상관관계는 멀티-채널 혹은 3차원 ConvLSTM을 적용할 수 있다. 향후 Deep-TraC 프레임워크에서 이러한 미세먼지, 날씨가 교통에 끼치는 영향이 포함될 것이다.

References

- [1] Deep Learning Tutorials, DeepLearning 0.1 documentation, [Online]. Available: <http://deeplearning.net/tutorial/>
- [2] Xiaolei Ma, Haiyang Yu, Yunpeng Wang and Yinhai Wang, "Large-scale transportation network congestion evolution prediction using deep learning theory," *PloS one*, 10(3):e0119044, 2015.
- [3] Hongsuk Yi, HeeJin Jung and Sanghoon Bae, "Deep Neural Networks for traffic flow prediction," *2017 IEEE International Conference on Big Data and Smart Computing (BigComp)*, pp. 328-331, 2017.
- [4] Ma, X., Tao, Z., Wang, Y., Yu, H. and Wang, Y., "Long short-term memory neural network for traffic speed prediction using remote microwave sensor data," *Transportation Research Part C: Emer-*

ging Technologies, 54, pp. 187-197, 2015.

- [5] Yi, H., Bui, KHN and Jung, H., "Implementing a deep learning framework for short term traffic flow prediction," *The 9th International Conference on Web Intelligence, Mining and Semantics (WIMS2019)*, pp. 1-8, 2019.
- [6] Khac-Hoai Nam Bui, Hongsuk Yi, HeeJin Jung, and Jinseok Seo, "Big data analytics-based urban traffic prediction using deep learning in ITS," *The 20th International Conference on Artificial Intelligence (ICAI19)*, pp. 270-273, 2019.
- [7] Hongsuk Yi, "Deep deterministic policy gradient for autonomous vehicle driving," *The 20th International Conference on Artificial Intelligence (ICAI'18)*, pp. 191-194, 2018.
- [8] Z. Zhao, W. Chen, X. Wu, P. C. Y. Chen and J. Liu, "LSTM network: a deep learning approach for short-term traffic forecast," *IET Intelligent Transport Systems*, Vol. 11, No. 2, pp. 68-75, 3. 2017.
- [9] Xingjian Shi, Zhouong Chen, Hao Wang and Dit-Yan Yeung, "Convolutional LSTM network: A machine learning approach for precipitation now-casting," *Advances in neural information processing systems*, pp. 802-810, 2015.



이 홍 석

1997년 서강대학교 물리학 박사. 1999년 한국과학기술정보연구원 슈퍼컴퓨팅응용센터 책임연구원. 관심분야는 딥러닝, 사물인식, 강화학습, 기계학습



부이 각 남

2019년 한국과학기술정보연구원 박사후연구원. 2014년 대만 진리대학교 컴퓨터과학및정보공학(석사). 2018년 중앙대학교 컴퓨터공학과(박사). 관심분야는 사물인터넷, 데이터 마이닝, 머신 러닝, 논리적 추론과 같은 AI 방법, 스마트 애플리케이션을 위한 딥러닝 모델



선 충 녕

2012년 서강대학교 컴퓨터공학과 박사 졸업. 2014년 한국과학기술정보연구원 융합서비스센터 선임연구원. 관심분야는 정보추출, 기계학습, 대화시스템 등