

---

저자 (Authors)	김병희, 이희용, 이순미
출처 (Source)	<a href="#">전자공학회지 46(11)</a> , 2019.11, 53-60(8 pages) <a href="#">The Magazine of the IEEE 46(11)</a> , 2019.11, 53-60(8 pages)
발행처 (Publisher)	<a href="#">대한전자공학회</a> The Institute of Electronics and Information Engineers
URL	<a href="http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE09281622">http://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE09281622</a>
APA Style	김병희, 이희용, 이순미 (2019). 무인항공기 대기측정센서 데이터와 LSTM 모델을 활용한 미세먼지(PM10) 농도 예측. 전자공학회지, 46(11), 53-60
이용정보 (Accessed)	부산도서관 210.103.83.*** 2021/09/24 14:02 (KST)

---

### 저작권 안내

DBpia에서 제공되는 모든 저작물의 저작권은 원저작자에게 있으며, 누리미디어는 각 저작물의 내용을 보증하거나 책임을 지지 않습니다. 그리고 DBpia에서 제공되는 저작물은 DBpia와 구독계약을 체결한 기관소속 이용자 혹은 해당 저작물의 개별 구매자가 비영리적으로만 이용할 수 있습니다. 그러므로 이에 위반하여 DBpia에서 제공되는 저작물을 복제, 전송 등의 방법으로 무단 이용하는 경우 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

### Copyright Information

Copyright of all literary works provided by DBpia belongs to the copyright holder(s) and Nurimedia does not guarantee contents of the literary work or assume responsibility for the same. In addition, the literary works provided by DBpia may only be used by the users affiliated to the institutions which executed a subscription agreement with DBpia or the individual purchasers of the literary work(s) for non-commercial purposes. Therefore, any person who illegally uses the literary works provided by DBpia by means of reproduction or transmission shall assume civil and criminal responsibility according to applicable laws and regulations.

# 무인항공기 대기측정센서 데이터와 LSTM 모델을 활용한 미세먼지(PM10) 농도 예측

## I. 서론

최근 전 세계적으로 대기오염으로 인한 조기 사망자(premature death) 증가와 의료비 증가 및 노동력 손실에 따른 경제적 손실 등에 대한 우려와 대책마련에 대한 요구가 높아지고 있다. 특히, 세계보건기구(WHO)에 의해 1군 발암물질로 분류된 미세먼지(Particulate Matter)로 인한 대기오염문제는 도시민의 건강뿐만 아니라 다른 대기오염물질과 반응하여 농작물과 생태계에 피해를 주는 등 사회·경제적 손실을 초래하기 때문에 효율적인 도시관리·운영과 도시민 삶의 질 향상을 위해서 반드시 해결해야 하는 과제이다<sup>[1]</sup>.

본 논문은 미세먼지로 인한 피해경감을 목적으로 하는 실시간 예측서비스에 대한 연구의 일환으로 무인항공기인 드론에 장착된 대기측정센서에서 실시간으로 생성되는 PM10, O3, NO2, CO, SO2 스트림 데이터를 수집하여 드론이 비행하는 주변공간의 미세먼지 농도를 실시간으로 예측하는 모델과 서비스를 제안한다. 본 논문에서 제안하는 미세먼지 농도 예측 모델은 딥러닝(deep learning) 기반의 신경망모델(neural network)인 LSTM(Long Short-Term Memory)<sup>[2]</sup>이며 수집데이터 처리 및 학습모델 생성과 모델 서빙을 위하여 KSB 인공지능 프레임워크<sup>[3]</sup>와 텐서플로우(Tensorflow)를 사용한다.

LSTM은 순환형 신경망(RNN, Recurrent Neural Networks)이 가지고 있는 경사 소실(vanishing gradient problem) 문제로 인하여 데이터의 장기 의존성(long term dependency)을 반영하지 못하는 단점을 개선한 모델로서, LSTM은 오래된 정보를 계속 유지할 수 있기 때문에 시퀀스의 초기에 입력된 중요정보가 시퀀스의 마지막에 영향을 줄 수 있는 것이 RNN과 비교했을 때의 장점이다.

본 논문에서 사용하는 데이터는 드론에 장착된 대기측정센서에서 생



김 병 희  
인천스마트시티(주) 선임연구원



이 희 용  
인천스마트시티(주) 연구소장



이 순 미  
인천스마트시티(주) 주임연구원

성하는 미세먼지(PM10), 오존(O3), 이산화질소(NO2), 일산화탄소(CO), 이산화황(SO2) 스트리밍 데이터를 수집한 것이다. ‘년-월-일-시-초’ 단위로 수집하는 시계열(time series)데이터는 시퀀스(sequence) 데이터로 변환되어 LSTM 모델의 학습데이터 셋으로 사용된다. 학습된 모델은 텐서플로우 서빙(Tensorflow-Serving)을 통하여 서빙되며 PM10 농도예측을 수행하게 된다.

수집된 스트리밍 데이터를 LSTM의 입력으로 사용하기 위해 먼저 1초 단위로 측정된 값들을 20초 단위 평균 값으로 계산하고, 이를 30개의 연속된 값으로 구성된 시퀀스 데이터로 변환시킨다. 이렇게 변환된 시퀀스 데이터는 LSTM의 입력 데이터로 사용되며, 출력 데이터는 다음 20초 후의 PM10 농도 예측 값이 된다.

LSTM 모델은 바로 인접한 데이터 셋으로의 이동과 정인 슬라이딩 윈도우(sliding window) 프로세스에 기반하여 학습한다. 활성화함수(activation function)는 비선형 함수(non-linear function)인 하이퍼볼릭탄젠트(Hyperbolic tangent function) 함수 및 softsign 함수가 학습에 사용되고, 모델의 성능은 Adam(Adaptive Moment Estimation: 적응적 모멘트 추정) 함수에 의해 최적화된다.

본 논문에서는 LSTM 예측 모델의 성능을 측정하기 위해 평균제곱근오차(RMSE, Root Mean Square Error)를 사용한다. RMSE는 실제 측정값과 학습된 모델의 예측 값 사이의 차이이며 RMSE가 0에 가까울수록 예측 성능이 좋다는 것을 의미한다.

본 논문은 2장에서는 관련연구를 분석하고, 3장에서는 LSTM을 이용한 PM10 농도 예측 모델을 기술한다. 4장에서는 예측서비스를 기술하고 5장에서는 본 논문의 결론 및 향후 연구과제에 대해 기술한다.

## II. 관련연구

### 1. 신경망을 활용한 미세먼지 농도 예측

신경망(Neural Network) 알고리즘을 활용한 미세먼지 농도 예측에 관한 연구는 주로 기상환경자료와 대기오염물질자료를 활용하고 있다. 통계적 모델은 수치모델에

비해 빠른 연산속도를 보이고 예측정확도가 높다는 점에서 많은 연구에서 이용되어 왔다. 최근에는 특히, 신경망(NN, Neural Network)모델을 이용한 연구들이 진행되어오고 있다<sup>[4][5][6][7][8][9]</sup>.

J. Lim<sup>[4]</sup>의 연구에서는 다중회귀분석(multiple regression analysis)을 통해 미세먼지농도에 유의한 영향을 미치는 변수를 추출하고 ANN(Artificial Neural Network)과 SVM(Support Vector Machine)을 사용하여 미세먼지 농도를 예측할 수 있는 모델을 제안하였는데 ANN을 사용한 미세먼지 예측모델이 가장 정확도가 높은 결과를 보여주었다.

J. Cha and J. Kim<sup>[5]</sup>의 연구에서는 ANN(Artificial Neural Network)알고리즘과 K-NN(K-Nearest Neighbor)알고리즘을 상호 응용하여 미세먼지 수치를 예측하고자 하였다.

K. Cho<sup>[6]</sup>의 연구에서는 DNN(Deep Neural Network) 모델을 구축하였는데 PM2.5에 대해서는 수치모델에 비해서 DNN 모델의 예측결과가 빈도를 기준으로 2배가량 더 정확하였고 계산 소요시간의 측면에서 DNN 모델의 성능은 매우 우수한 것으로 나타났으나 하루 단위로 농도변화가 급격하게 나타났던 다른 오염물질에 대해서는 DNN 모델 예측결과가 상대적으로 더 부정확하다는 결과를 보여주었다.

T. Kang and J. Kang<sup>[7]</sup> 등의 연구에서는 측정소가 없는 지역의 미세먼지를 수치를 DANN(Domain Adversarial Neural Network)를 이용하여 예측하였으나, 미세먼지가 농도가 갖는 시간, 위치에 따른 변화를 반영하지 못한다는 한계를 보였다.

S. Jeon and Y. Son<sup>[8]</sup>의 연구에서는 국내 기상환경자료뿐만 아니라 전일 및 이를 전 중국의 미세먼지 농도와 계절변수를 예측변수에 추가하여 DNN(Deep Neural Network), SVM(Support Vector Machine), 다항로지스틱(Multinomial Logistic), 랜덤포레스트(Random Forest) 사용하여 익일의 미세먼지 수치를 예측하였다.

S. Kim and T. Oh<sup>[9]</sup>의 연구에서는 IoT 센서로부터 생성되는 스트리밍 데이터에 기반하여 실시간 실내 PM10 농도 예측 LSTM 모델과 서비스를 제안하였는데, 제안한

LSTM 예측 모델이 선형 회귀 및 RNN 모델보다 성능 개선이 있음을 보여주었다. 기존의 연구에서는 기본적으로 기상환경자료와 대기오염물질자료를 토대로 다양한 기계 학습 알고리즘을 활용하여 학습모델을 구축하고 예측 모델의 성능비교에 중점을 두고 있다.

## 2. 드론의 활용

드론(Drone)이란 우리나라의 항공안전법에서 ‘초경량 비행장치’로 항공기와 경량항공기외에 공기의 반작용으로 뜰 수 있는 장치로서 자체 중량, 좌석 수 등 국토교통 부령으로 정하는 기준에 해당하는 동력비행장치, 행글라이더, 페러글라이더, 기구류 및 무인비행장치 등을 말한다. 드론은 군사 목적을 위해 개발되었으나 비행제어 알고리즘의 발전, 소재의 경량화, 저렴해진 가격으로 최근에는 군사용뿐만 아니라 농업용, 촬영용, 레저용 등 다양한 분야에서 사용되고 있다.

드론은 부착된 카메라나 센서 등을 이용해 계속된 데이터들을 무선 네트워크를 이용하여 지상관제시스템에 송신하여 역할을 수행하고 있는데 이를 통해 공중에서 발생하는 다양한 이벤트의 신속한 관측이 가능해졌다<sup>[10]</sup>. 또한 드론을 조종하기 위해 숙련된 조종자가 반드시 필요했던 예전과 달리, 드론에 FC(Flight Controller)를 장착하면 조종기를 이용하지 않고 지상관제시스템을 이용하여 드론의 이착륙, 비행경로까지 조종할 수 있다.

드론은 고위험에 노출된 환경 같은 사람의 직접적인 접근이 힘든 지역과 사람이 장시간에 걸쳐 해야 하는 일을 빠르고 효율적으로 처리할 수 있다. 대기오염이 심각해지면서 드론을 활용하여 이를 예방 및 해결하기 위한 노력이 국내외로 진행되고 있다. 기존에는 고정형 측정소, 유인비행기를 이용하였으나 한정된 측정구역과 많은 비용이 요구된다는 단점을 보완하기 위한 해결책으로 드론이 사용되는 것이다. 미세먼지의 모니터링을 위해 올해 환경부에서는 드론으로 대기오염물질의 농도를 실시간으로 정밀 분석하여 고농도의 배출지역과 오염물질을 추적하는 시범 단속하는 ‘미세먼지 감시팀’을 설립하였다. 일본의 한 업체에서는 실내의 미세먼지를 제거하는 드론을 출시하였으며, 태국에서는 미세먼지 제거를 위해 드론으로

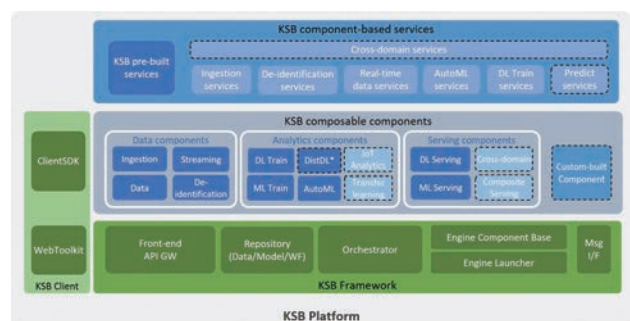
상공에 물을 살포하였다.

연구개발도 끊임없이 이루어지고 있는데 기상청, 한양대학교, 한국건설기술연구원, 호남대 등에서 드론에 부착한 센서를 통해 실시간으로 관측되는 미세먼지 및 오염도의 정확도를 향상시키기 위한 연구, 대기오염을 줄이기 위한 정책수립단계에서 드론의 활용법 연구, 드론으로 관측한 정보를 바탕으로 빅데이터 분석 및 예측에 관한 연구를 진행하였다<sup>[11][12][13]</sup>.

드론 비행은 우리나라 항공안전법 제129조 및 시행규칙 제310조에 따라 비행구역과 비행가능 시간에 제한이 있기 때문에 드론을 활용한 실시간 대기오염물질 측정에 한계가 있다는 점에 유의할 필요가 있다.

## 3. KSB 인공지능 프레임워크

KSB(Knowledge-converged Super Brain) 인공지능 프레임워크는 한국전자통신연구원(ETRI, Electronics and Telecommunications Research Institute)의 KSB 융합연구단이 개발한 인공지능 프레임워크로서 IoT, 빅데이터, 기계학습 및 도메인 지식을 융합하여 인공지능 서비스 구축에 필요한 공통기능을 제공한다. 또한, KSB 인공지능 프레임워크는 분산병렬 인프라를 기반으로 다양한 데이터 소스로부터 도메인 응용서비스 제공까지의 전주기적 솔루션을 지향하며 멀티모달 데이터처리, 멀티모델 동시학습 및 추론, 자동기계학습, 분산병렬학습 및 추론, 학습모델 및 도메인지식의 탑재·연동을 워크플로우(Workflow) 기반으로 선택·조합·실행·서빙 및 재 활용 가능한 구조로 설계되어있다.



〈그림 1〉 KSB 인공지능 프레임워크 구조



〈그림 1〉은 KSB 인공지능 프레임워크의 코어구조를 보여준다. 기본적으로 하둡(Hadoop) 및 스파크(Spark)를 기반으로 하고 있으며 KSB components는 데이터의 수집·적재·처리를 담당하는 Data Components, 모델 학습을 담당하는 Analytics Components, 모델 서빙을 담당하는 Serving Components로 구성되어 있다<sup>[14]</sup>.

Components는 CientSDK 또는 WebToolkit을 통해 엔진(Engine)으로 구성할 수 있으며 프레임워크 사용자는 engine을 통해 데이터 수집부터 예측까지 단계별로 개발이 가능하다.

### III. 예측모델

#### 1. LSTM 알고리즘

본 논문에서는 PM10 농도 예측을 위하여 순환신경망(RNN, Recurrent Neural Networks)의 일종인 LSTM(Long Short-Term Memory)을 사용한다.

RNN은 과거의 데이터가 미래의 결과에 영향을 줄 수 있는 순환 구조(directed cycle)를 가지고 있으며 연속적(sequence)인 속성을 띄고 있는 데이터인 번역, 문자, 음성 인식 등의 분야에서 활용되고 있다. 그러나 RNN은 비용함수(cost function)을 최소화하기 위하여 파라미터를 조정해나가는 방식인 경사하강법(gradient descent)을 사용하는데, 학습과정에서 긴 시퀀스를 처리하는데

있어서 이전의 정보가 time step따라 소실되는 경사 소실(vanishing gradient) 문제가 발생하여 데이터의 장기 의존성(long-term dependency)을 고려하는데 한계가 있다.

LSTM(Long Short-Term Memory models)은 RNN의 장기 의존성 문제를 해결하기 위하여 Hochreiter, S., & Schmidhuber, J. (1997)이 제안한 컨셉이다<sup>[15]</sup>.

〈그림 1〉은 LSTM의 구조를 보여준다. LSTM은 Cell State, Forget Gate, Input Gate, Output Gate으로 구성되며 각 Gate에서의 벡터 출력 값은 sigmoid layer와 tanh layer를 거쳐 생성된다. LSTM은 명시적으로 과거의 정보를 다음 State으로 넘기는 구조를 사용하여 장기 의존성을 학습하며 Cell State는 과거의 정보를 다음 타임 스텝으로 전달하는 역할을 한다.

Forget Gate는  $h_{t-1}$ 과  $x_t$ 를 입력 값으로 받아 활성화 함수인 Sigmoid 함수를  $\sigma$ 를 취해준 값  $f_t$ 을 출력하며 Cell state로의 정보 전달 여부를 결정하는 역할을 한다〈수식 (1)참조〉.  $f_t$ 는 Sigmoid 함수의 출력 값이므로 0과 1사이의 값을 갖게 되는데, 이 값이 1에 가까울수록 미분 값인 경사(gradient)가 소멸(vanished)되는 것을 줄일 수 있게 된다. 즉,  $f_t$ 가 1에 가깝다는 것은 Cell state 입장에서는 과거의 오래된 정보(long term memory)에 의한 영향을 받는다는 것이고 time step에 따라 gradient 또한 오래 유지된다는 것으로 해석할 수 있다.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

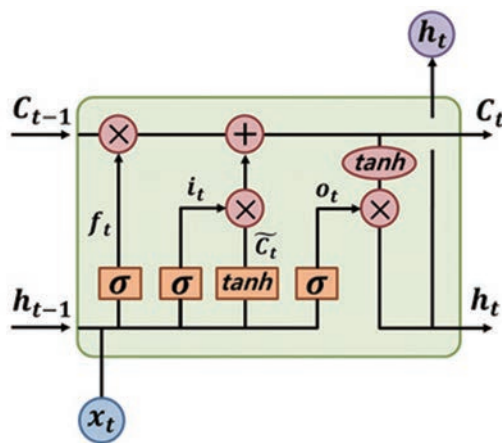
Input Gate는 Cell State에 업데이트할 정보를 결정하는 역할을 한다〈수식 (2)참조〉. 그리고 layer는 활성화 함수인 hyperbolic tangent 함수를 취하여 Cell State에 더해질 후보 값  $\tilde{C}_t$ 를 만들어낸다〈수식 (3)참조〉.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (3)$$

수식 (4)에서 보듯이 이전 Cell State의 값  $C_{t-1}$ 과  $f_t$ 의 element-wise product 및  $i_t$ 와  $\tilde{C}_t$ 의 element-wise product를 수행 후 더하여 다음 time step으로 전달할 새로운 Cell State 값  $C_t$ 를 생성한다.

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (4)$$



〈그림 2〉 LSTM 구조

수식 (5)와 수식(6)은 Output Gate 의 역할을 보여준다. Sigmoid layer의 출력 값  $o_t$  와 갱신된 Cell State 값  $C_t$  에 hyperbolic tangent 함수를 취한 값을 element-wise product 수행하여 출력 값  $h_t$  를 생성하게 된다.

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5)$$

$$h_t = o_t * \tanh(C_t) \quad (6)$$

## 2. 미세먼지 농도예측 LSTM 모델

본 논문에서는 드론에 장착된 대기측정센서로부터 수집한 PM10, O3, NO2, CO, SO2의 스트리밍 데이터를 LSTM 의 입력데이터로 사용하여 미세먼지 농도 예측을 위한 학습모델을 생성한다.

〈그림 3〉은 LSTM예측모델을 구축하는 과정을 보여준다.

실시간 측정값은 서버로 전송되어 초 단위의 값으로 DB에 저장된다. 수집된 데이터는 결측값(missing value)과 이상값(outlier)을 제거하고, 0과 1사이의 값으로 최대 최소정규화(min-max normalization)을 거쳐 LSTM 학습을 위한 시퀀스(sequence)데이터로 변환된다. 본 논문에서는 슬라이딩 윈도우(sliding window) 방법을 이용하여 1초 단위의 약 21,600 여개의 시계열 데이터 스트림을 20초 단위의 평균값으로 계산하여 30개의 연속된 값들을 갖는 시퀀스 데이터 셋으로 변환시켜 입력데이터(Input data)로 사용한다.

변환된 전체 데이터 셋에서 70%인 756개 셋은 LSTM 모델의 학습데이터(Training set)로 사용되고, 30%인 324개 셋은 학습모델의 성능평가를 위한 테스트 데이터

(Test set)로 사용한다.

변환된 학습데이터는 KSB 프레임워크에서 Python으로 구축된 구글 텐서플로우(Tensorflow)기반의 LSTM 알고리즘을 통해 학습되며, 서빙(serving)된 모델은 PM10 농도 예측을 수행한다.

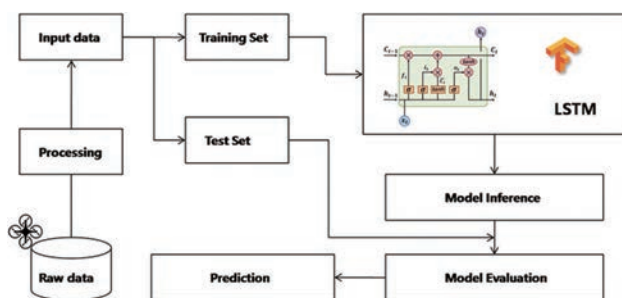
본 논문에서는 LSTM 모델을 최적화(Optimizing)하기 위해 Diederik Kingma 와 Jimmy Ba가 제안한 기법인 Adam(Adaptive Moment Estimation: 적응적 모멘트 추정) 최적화 함수를 사용한다<sup>[16]</sup>. Adam은 RMSProp 와 Momentum의 방법을 동시에 이용하는데, learning rate를 1/2씩 exponential하게 줄여주는 기능을 수행하여 알고리즘 성능을 최적화시키며 일반적으로 Neural Network 학습에서 많이 사용되는 Optimizer 이다<sup>[17]</sup>.

본 논문에서는 LSTM모델 평가 알고리즘으로 평균제곱근오차(RMSE, Root Mean Square Error)를 사용한다. 수식 (7)에서 보는바와 같이 RMSE는 모델에 의해 생성된 예측 데이터( $P_i$ )와 실측 데이터( $A_i$ ) 값의 차이에 제곱근을 취한 것으로, 두 데이터의 오차를 보여주는 방법으로 값이 0에 가까울수록 더 좋은 성능을 의미한다.


$$RMSE = \sqrt{\frac{\sum_i^n (P_i - A_i)^2}{n}} \quad (7)$$

〈그림 4〉은 학습반복횟수(epoch)에 따른 손실함수(Loss Function)인 RMSE를 보여준다.


본 논문에서는 최적화 함수의 경우 Adam 과 RMSProp 로 나누고 활성화 함수를 tanh과 softsign으로 나누어 학



〈그림 3〉 LSTM 예측모델 구축과정



〈그림 4〉 반복횟수에 따른 RMSE그래프



〈그림 5〉 PM10의 예측값과 실측값 비교

습을 진행한 결과, Adam 최적화 함수와 softsign 활성화 함수를 적용했을 때 RMSE 값이 0.035로 가장 적은 오차 값을 나타냈다.

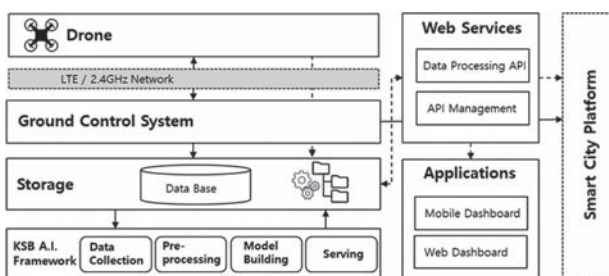
〈그림 5〉는 LSTM모델에 의한 미세먼지 PM10의 실측값(빨간색)과 예측값(파란색)의 비교를 보여 준다.

## IV. 예측서비스

### 1. 서비스구성

〈그림 6〉은 본 논문에서 제안하는 LSTM 예측모델을 사용한 PM10 농도 예측 서비스의 구조를 보여준다.

서비스구조는 대기질을 측정하여 농도 데이터를 전송하는 드론, 드론을 제어하고 데이터를 전송받아 DB에 저장하는 지상관제시스템(GCS, Ground Control System), 데이터를 수집하여 전처리 후 텐서플로우 기반으로 LSTM모델을 학습하고 서빙하는 KSB 인공지능 프레임워크와 이들 간의 인터페이스를 관리하는 Web Service를 담당하는 WAS(Web Application Server)로



〈그림 6〉 예측 서비스 구조

구성된다.

Web Service에서 예측에 필요한 데이터와 함께 예측값을 요청하면 KSB 인공지능 프레임워크에서는 TensorFlow Serving REST API를 통하여 LSTM 모델에 의해 예측한 값을 RESTful 로 응답하게 되며 WAS는 이 값을 Applications 및 도시 관제를 위해 사용하는 Smart City Platform에 제공하게 된다.

### 2. 드론


본 논문에서 사용한 드론은 〈그림 7〉과 같이 Octa-copter 회전익(multi-copter)으로 DJI S1000 PLUS 프레임에 FC는 Pixhawk 2.1을 사용하고, EO/IR 카메라, 대기측정센서, GPS센서를 장착하였다. 배터리는 Tattu 22000mAh 리튬 폴리머 배터리(Lipo Battery)를 사용하였다. 비행시간은 회당 10분이며 순항속도 15km/h, 상승속도 5m/s, 비행고도는 항공안전법상 비행제한고도인 150m 미만을 유지하였다.

〈그림 8〉는 드론이 측정한 대기오염물질 중 PM10의 비행경로별 농도 분포도를 나타낸다.

드론은 지상관제시스템(GCS, Ground Control



〈그림 7〉 드론 외관



〈그림 8〉 비행경로에 따른 PM10농도 분포도

System)을 통해서 제어할 수 있는데, GCS에서 설정한 경로점(waypoint)를 따라 비행을 하게 된다. 따라서, 대기질 측정공간이 시간에 따라 변화한다는 특징이 있다. 또한, 자이로센서 및 GPS센서를 장착하고 있으므로 위도 및 경도에 따른 대기질 실시간 모니터링이 가능하다. 경로별 비행시간의 충분한 확보는 예측에 필요한 데이터양이 증가한다는 것을 의미하므로 모델 성능개선에 도움을 줄 수 있다.

## V. 결론

본 논문에서는 드론에 장착된 대기측정센서에서 생성한 PM10, O3, NO2, CO, SO2의 스트리밍 데이터를 수집하고, KSB 인공지능 프레임워크를 활용하여 LSTM 기반의 PM10 농도 예측 모델 및 서비스를 제안하였다.

본 논문은 사용한 드론의 대수와 배터리 용량에 따른 비행시간의 제약으로 예측모델 구축을 위한 학습데이터의 수가 적었고 기상환경인자를 고려하지 않았다는 점에서 한계를 보인다. 그러나 드론은 비행거리와 비행시간의 한계가 있음에도 불구하고 실시간 대기질 측정과 빠른 기동성을 통한 오염원 추적이 가능하다는 장점에 착안하여 실시간 PM10 예측 모델의 활용가능성을 제시한다는 점에 의의가 있다.

향후에는 비행시간이 긴 고정익 드론 및 복수개의 드론을 활용하는 방법으로 데이터 확보를 용이하게 하고 비행에 따른 대기질 측정 공간 변화를 고려하며, 비행경로 주변(ambient) 대기의 기상관측 값을 예측변수로 추가하여 다양한 신경망모델을 활용하는 등의 지속적인 연구를 진행할 예정이다.

## 참고 문헌

- [1] OECD, "The economic consequences of outdoor air pollution," <https://www.oecd.org/environment/indicators-modelling-outlooks/Policy-Highlights-Economic-consequences-of-outdoor-air-pollution-web.pdf>
- [2] Christopher Olah, "Understanding LSTM Networks," <https://www.cse.iitk.ac.in/users/sigml/lec/Slides/LSTM.pdf>

- [3] <https://csleoss.etri.re.kr/>
- [4] J. Lim, "An Estimation Model of Fine Dust Concentration Using Meteorological Environment Data and Machine Learning," *Journal of Information Technology Services*, Vol. 18, No. 1, pp.173–186, March 2019.
- [5] J. Cha and J. Kim, "Development of Data Mining Algorithm for Implementation of Fine Dust Numerical Prediction Model," *Journal of the Korea Institute of Information and Communication Engineering*, Vol. 22, No. 4, pp. 595~601, April 2018.
- [6] K. Cho, B. Lee, M. Kwon and S. Kim, "Air Quality Prediction Using a Deep Neural Network Model," *Journal of Korean Society for Atmospheric Environment*, Vol. 35, no. 2, pp. 214–225, April 2019.
- [7] T. Kang and H. Kang, "Machine Learning-based Estimation of the Concentration of Fine Particulate Matter Using Domain Adaptation Method," *Journal of Korea Multimedia Society*, Vol. 22, No. 8, pp. 1208–1215, August 2017.
- [8] S. Jeon and Y. Son, "Prediction of fine dust PM10 using a deep neural network model," *The Korean Journal of Applied Statistics*, Vol. 31, No. 2, pp. 265–285, March 2018.
- [9] S. Kim and T. Oh, "Real-time PM10 Concentration Prediction LSTM Model based on IoT Streaming Sensor data," *Journal of the Korea Academia-Industrial cooperation Society*, Vol. 19, no. 11, pp. 310–318, November 2018.
- [10] T. Kim, J. Song, H. Lim and B. Kim, "Drone Deployment Using Coverage-and-Energy-Oriented Technique in Drone-Based Wireless Sensor Network," *Journal of the Korea Academia-Industrial cooperation Society*, Vol. 20, No. 8, pp. 15–22, August 2019.
- [11] N. Kim, "Development of atmospheric environment information collection system using drone," *Smart Media Journal*, Vol. 7, No. 4, pp. 44–51, December 2018.
- [12] Y. Jo, S. Baek, J. Lee, S. Yu, M. Jang and Y. Lee, "Suggestion of Device for Collecting Fine Dust using Drone," *Korean Society of Computer Information*, Vol. 27, No. 2, pp. 397–400, July 2019.
- [13] J. Kim, E. Lee and J. Lee, "Predicting and Analyzing Big Data





of Fine Dust Using Drone," Korea Information Processing Society, Vol. 24, No. 2, pp. 1195–1198, November 2017.

[14] [https://pcm.etri.re.kr/pcm/getFile.do?file\\_cd=12412](https://pcm.etri.re.kr/pcm/getFile.do?file_cd=12412)

[15] Sepp Hochreiter and Jürgen Schmidhuber "Long Short-Term Memory, " Neural Computation, Vol. 9, no. 8, pp. 1735–1780, November 1997.

[16] Diederik P. Kingma and Jimmy Ba, "Adam: A Method for Stochastic Optimization, " in Proc. of 3rd International Conference for Learning Representations, San Diego, USA, May 2015.

[17] H. Lim, J. Kim, D. Kwon and Y. Han, "Comparison Analysis of TensorFlow's Optimizer Based on MNIST's CNN Model, " Journal of Advanced Technology Research, Vol. 2, no. 1, pp. 1–14, June 2017.



김 병 희

- 2014년 성균관대학교 대학원 경영학 MIS 전공 석사
- 2017년 서울대학교 대학원 응용공학 Bigdata&AI 트랙수료
- 2018년 ~ 현재 인천스마트시티(주) 연구소 선임연구원

〈관심 분야〉

신경망, 비즈니스 인텔리전스, 스마트시티



이 희 용

- 1996년 서울시립대학교 도시공학과 석사수료
- 1999년 ~ 2001년 국토연구원
- 2003년 ~ 2010년 선도소프트
- 2010년 ~ 2013년 아시아나HDT
- 2013년 ~ 현재 인천스마트시티(주) 연구소장, 과학기술 정보통신부 기술수준평가 전문가 (스마트시티 구축 및 운영 기술 분야)

〈관심 분야〉

스마트시티, 드론, IoT



이 순 미

- 2017년 한서대학교 무인항공기학 학사
- 2018년 ~ 현재 인천스마트시티(주) 연구소 주임 연구원

〈관심 분야〉

드론, 무선통신시스템, 인공지능